

Oblig 2 - STK1110

Oppg. 1

```
path="https://www.uio.no/studier/emner/matnat/math/STK1110/data/temp.txt"
data =read.table(path,header=T)

# a. boxplot og normalfordelingsplot.
boxplot(data, xlab="kjønn", ylab="C", main="Kroppstemperatur pr. kjønn")

qqnorm(data$Menn, main="qqnorm Menn")
qqline(data$Menn)
qqnorm(data$Kvinner, main="qqnorm Kvinner")
qqline(data$Kvinner)
#ser nogen lunde normalt ut. Dog men har litt større ekstremaliteter

# b. alfa = 0.05, H0: mu_menn == mu_kvinner altså del_0 = 0, Ha: mu_menn != mu_kvinner
# x:menn, x:kvinner
alfa =0.05
x = data$Menn
y = data$Kvinner
#mellomregning
mean.x = mean(x)
mean.y = mean(y)
sd.x = sd(x)
sd.y = sd(y)
m = length(x)
n = length(y)
se.x = sd.x/sqrt(m)
se.y = sd.y/sqrt(n)

df = ( (se.x)^2 + (se.y)^2 )^2 / ( (((se.x)^4)/(m-1)) + ((se.y)^4/(n-1)) )
t_obs = (mean.x - mean.y) / sqrt( (sd.x^2)/m + (sd.y^2)/n )

p.t_obs = pt(t_obs, df) # = 0.015 > alfa/2 så vi kan forkaste null hypotesen med stor margin
# todo: ser ut til av vi skal ha sd.x = sd.y, må finne mer ut om dette.

#c. F-test
f = Sd.x^2/sd.x^2
```

Oppg 2

```

# oppg 2

# twin A: at biological parents, twin B: not
# Q: is there difference in IQ

#data
A.n = 31
A.mean = 93.32
A.sd = 15.41
A.se_mean = 2.77

B.n = 31
B.mean = 96.58
B.sd = 13.84
B.se_mean = 2.49

diff.N = 31
diff.mean = -3.26
diff.sd = 8.81
diff.se_mean = 1.58

#a
# Vi burde ha en paret sammenligning siden:
# Vi sammenligner to resulater, og ikke et nytt resultat mot et tidligere.
# Vi maa anta at:
# X1, X2, ... , Xm er uavhengige og identisk fordelte, med forventningsverdi mu_x
# og varians sigma_x
# tillsvarende for Y.
# og vi må ha at Xi og Yi er uavhengige.

#b
#Hypotesetest: H0: A - B = mu_D == 0, mot Ha: A - B = mu_D != 0

mu_D = A.mean - B.mean
#df
#se.x = sd.x/sqrt(m)
#se.y = sd.y/sqrt(n)

df = ( (A.se_mean)^2 + (B.se_mean)^2 )^2 / ( (((A.se_mean)^4)/(A.n-1)) +
((B.se_mean)^4/(B.n-1)) ) # frihetsgrader
t_obs = (A.mean - B.mean - 0) / sqrt( (A.sd/A.n) + (B.sd/B.n) )

P.val = pt(t_obs, df) # hvis denne er regnet rett er det stor grunn til å forkaste
H0

#c
alfa = 0.05
diff.Ci = diff.mean + c(1,-1) * qt(alfa/2, df) * sqrt( (A.sd/A.n) + (B.sd/B.n) )
# det at diff.Ci bare dekker negative verdier forteller at vi er mer en .95 sikker
# på at den sanne verdien er negative, siden vi er .95 sikker på at den sanne
# verdien ligger innenfor vaart CI.
# En slik tosidig test, tester om vi er lengere unna, enn an størrelse beskrevet
# av alfa/2, mu fra H0.

```

```
# Mens en ensidig test tester om test observatoren er en sørrelse beskrevet av alfa, mindre enn mu fra H0.
```

Oppg 3

```
# notation: Yi = b0 + b1*Xi + ei
# b1: slope coefficient,
# Y: responsvariabel
# xi forklaringsvariabel.
path="https://www.uio.no/studier/emner/matnat/math/STK1110/data/plastic.txt"
plast=read.table(path,header=T)

# a
# Strenght = respons = Y
# Temperature = forklaringsvariable = Xi
Y = plast$Strength
X = plast$Temperature
X.mean = mean(X)
Y.mean = mean(Y)
X.n = length(X)
Y.n = length(Y)

b1 = (sum((X-X.mean)*(Y-Y.mean))) / sum((X-X.mean)**2) # = Sxy/Sxx
b0 = (sum(Y) - b1*sum(X))/X.n # Y.mean - b1*X.mean

# plot
plot(X, Y, xlab="Temperature", ylab="Strength")
abline(b0, b1)
# kommentar:
# Regresjonslinjen ser ut til å stemme. Standardfeilen er dog stor rundt Temp
= 200

# b) CI for regresjonskoeffisienten for Temperature. Git intervallet indikasjon på om temperatur er en viktig forklaringsvariabel
# CI for the slope B1:
# b1 +- t_alfa/2,n-2 * Sb1
alfa = 0.05
S2 = (sum(Y^2) - b0*sum(Y) - b1*sum(X*Y)) / (X.n-1)
S = sqrt(S2)
Sxx = sum((X- X.mean)^2)
Sb1 = S/sqrt(Sxx)

b1.CI = b1 + c(1,-1) * qt(alfa/2, X.n-2) * Sb1
t_ratio = b1 / Sb1

# t_ratio er betydelig større en max(b1.CI) så dermed forkaster vi b1.CI

# c)
Sy = S * sqrt( (1/Y.n) + (X - X.mean)^2/Sxx ) # dont know which N to use
Y.CI.m = b0+b1*X - qt(alfa/2, Y.n-2) * Sy # same here
```

```

Y.CI.p = b0+b1*X + qt(alfa/2, Y.n-2) * Sy # same here

# PI
# b0 + b1*x +- t(alfa/2, n-2) * S * sqrt( 1 + 1/n + (X - X.mean)/sXX )
x_star = c(210, 240, 270)
y_hat = b0 + b1 * x_star
PI <- function(b0, b1, x, x_mean, S, Sxx, n) {
  p = b0 + b1*x + qt(alfa/2, n-2) * S * sqrt(1+1/n+(x-x_mean)^2/Sxx)
  m = b0 + b1*x - qt(alfa/2, n-2) * S * sqrt(1+1/n+(x-x_mean)^2/Sxx)
  res = data.frame(p, m)
  colnames(res) <- c("p", "m")

  return(res)
}
# Y.PI.x_star.p = ( b0 + b1*x_star ) + qt(alfa/2, Y.n-2) * S * sqrt( 1 + 1/Y.n +
# (X - X.mean)/Sxx )
# Y.PI.x_star.m = ( b0 + b1*x_star ) - qt(alfa/2, Y.n-2) * S * sqrt( 1 + 1/Y.n +
# (X - X.mean)/Sxx )
Y.PI.1 = PI(b0, b1, x_star[1], X.mean, S, Sxx, Y.n)
Y.PI.2 = PI(b0, b1, x_star[2], X.mean, S, Sxx, Y.n)
Y.PI.3 = PI(b0, b1, x_star[3], X.mean, S, Sxx, Y.n)

# d)
X2 = plast$Pressure
S2 = (sum(Y^2) - b0*sum(Y) - b1*sum(X2*Y)) / (X.n-1)
S = sqrt(S2)
sum((X2- X.mean)^2)
Sy = S * sqrt( (1/Y.n) + (X - X.mean)^2/Sxx )
reg_estimate <- function(Y, X) {
  n = length(Y)
  b1 = sum((X - mean(X)) * (Y - mean(Y))) / sum((X - mean(X))^2)
  b0 = (sum(Y - b1) * sum(X)) / n
  coeffs = data.frame(b0 = b0, b1 = b1)
  return(coeffs)
}

CI <- function(b0, b1, x, n, alfa, Sy) {
  Sy = S
  p = b0+b1*x + qt(alfa/2, n-2) * Sy
  m = b0+b1*x + qt(alfa/2, n-2) * Sy
  return data.frame(
    p = p,
    m = m
  )
}

estimate = reg_estimate(Y, X2)
b0 = estimate$b0
b1 = estimate$b1
Y.CI = CI(b0, b1, X2, Y.n, alfa, Sy2)

```

4/ a) Vis at minste kvaraters estimator

$$\text{for } \beta \text{ er } \hat{\beta} = \frac{\sum x_i y_i}{\sum x_i^2}$$

Vi skal maksimere funksjonen

$$f(\beta) = \sum (y_i - \beta x_i)^2 = \sum y_i^2 - 2 y_i \cdot \beta x_i + \beta^2 x_i^2$$

Permed deriverer jeg og setter lik 0

$$\frac{\partial f(\beta)}{\partial \beta} = \sum \cancel{y_i^2} - 2 y_i x_i + 2 \beta x_i^2 = 0$$

Løser for β

$$0 = \sum -2 y_i x_i + 2 \beta x_i^2 \quad / \cdot -1, -\{2 \beta x_i^2, \frac{1}{2}\}$$

$$\beta \sum x_i^2 = \sum y_i x_i \quad | \frac{1}{\sum x_i^2}$$

$$\hat{\beta} = \frac{\sum y_i x_i}{\sum x_i^2}$$

□

$$n(\bar{t}) = \frac{\hat{\beta} - \beta}{S} \sqrt{\sum x^2}$$

Det kan skrives som

$$\bar{t} = \frac{\hat{\beta} - \beta}{\frac{S}{\sqrt{\sum x^2}}}$$

Som kan skrives som

$$\bar{t} = \frac{\hat{\beta} - \beta}{\frac{\sigma}{\sqrt{N_{\text{Sxx}}}}} \sqrt{\frac{(n-1)S^2/\sigma^2}{(n-1)}}$$

Videt at $\frac{\hat{\beta} - \beta}{\sigma/\sqrt{N_{\text{Sxx}}}}$ er normalfordelt $\sim N(0, 1)$

og at $(n-1)S^2/\sigma^2$ er kji-kvadratfordelt
og et en standard normal tilfældig variabel
delt på røten av en kji-kvadrat er
en t-fordeling

t

4)

Setter opp Hypotesetest

$$H_0: \beta = \beta_0, H_a: \beta \neq \beta_0$$

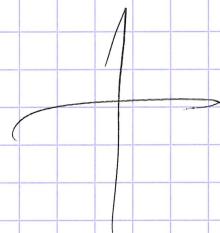
(1) for $\hat{\beta}$ blir

$$\hat{\beta} \pm t_{\alpha/2, n-1} s_{\beta}$$

$n-1$: sider vi har en parameter

$\alpha/2$ sider vi har forsiktig test

$$s_{\beta} =$$



4 d) Sönder upp Hypoteserst

$$H_0: \beta = \beta_0 \quad , \quad H_a: \beta \neq \beta_0$$

Testverd

$$t = \frac{\hat{\beta} - \beta_0}{S} \sqrt{\sum x_i^2}$$

Förhållan H_0 hvis

$$|t| \geq t_{\alpha/2, n-1} \text{ eller } |t| \leq -t_{\alpha/2, n-1}$$

Där α är signifikansverdi

□

e) Vis at

$$\sum(Y_i - \hat{\beta}x_i)^2 = \sum Y_i^2 - \hat{\beta}^2 \sum x_i^2$$

Løsne hovedruter

$$\sum Y_i^2 - 2\hat{\beta}\sum x_i + \hat{\beta}^2 \sum x_i^2$$

$$\sum Y_i^2 + \sum \hat{\beta}^2 x_i^2$$